Atelier Machine Learning

Analyse Comportementale Clientele Retail

COMPTE RENDU

Atelier Pratique : E-commerce de Cadeaux

Prepare par Mohamed yassine trigui

Annee Universitaire : 2025-2026

Table des matières

1 Contexte du projet **2**

2 Structure du projet **2**

3 Etapes de realisation du projet **2**
3.1 1) Preparation de l'environnement 2
3.2 2) Preparation des donnees 2
3.3 3) Decoupage train/test et normalisation 2
3.4 4) Entrainement des modeles 3
3.5 5) Evaluation 3
3.6 6) Mise en production locale (Flask) 3
3.7 7) Bonnes pratiques suivies 3

4 Captures d'ecran et preuves de travail **3**
4.1 Vue globale du pipeline 3
4.2 Sortie de pretraitement 3
4.3 suppression de corrélation 3
4.4 Performance des modeles 3
4.5 Interface Flask de prediction 3
4.6 Conseil de capture 3

5 Conclusion et perspectives **7**
5.1 Ameliorations possibles 7

1 Contexte du projet

Ce projet traite une base e-commerce de clients retail et vise a comprendre le comportement d'achat pour :

- predire le churn,
- segmenter les clients,
- estimer le montant des achats.

Le pipeline est implemente en Python avec des scripts dedies dans le dossier `src/`, une application Flask dans `app/`, et des artefacts de modeles dans `models/`.

2 Structure du projet

Dossier / Fichier	Role
`data/raw/`	Donnees brutes (CSV source).
`data/processed/`	Donnees nettoyees.
`data/train_test/`	Jeux `X_train`, `X_test`, `y_train`, `y_test`.
`src/preprocessing.py`	Nettoyage, imputation, encodage, normalisation, split.
`src/train_model.py`	PCA, clustering, classification, regression et evaluation.
`src/predict.py`	Chargement des modeles et prediction sur nouveaux clients.
`app/app.py`	Interface web Flask pour la prediction churn.
`models/`	Modeles sauvegardes (`.pkl`).
`reports/`	Graphiques et sorties visuelles.

3 Etapes de realisation du projet

3.1 1) Preparation de l'environnement

Objectif

Installer l'environnement Python et les dependances du projet.

```
python -m venv venv
venv\Scripts\activate
pip install -r requirements.txt
```

Listing 1 – Installation initiale

3.2 2) Preparation des donnees

- Chargement du fichier source CSV depuis `data/raw/`.
- Nettoyage des valeurs aberrantes (tickets support, score satisfaction, bornes monetaires).
- Imputation des donnees manquantes numeriques et categorielles.
- Encodage des variables (ordinal + one-hot + frequence pays).
- Reduction de la colinearite.

3.3 3) Decoupage train/test et normalisation

- Split stratifie train/test.
- Sauvegarde des fichiers dans `data/train_test/`.
- Standardisation des features avec `StandardScaler`.

3.4 4) Entrainement des modeles

- **PCA** pour reduction de dimension et visualisation.
- **K-Means** pour la segmentation clientele.
- **Classification churn** avec Regression Logistique et Random Forest.
- **Regression** du montant total via Ridge.

3.5 5) Evaluation

- Classification : rapport de classification, matrice de confusion, courbe ROC, AUC.
- Regression : RMSE et R^2.
- Sauvegarde des graphiques dans `reports/`.

3.6 6) Mise en production locale (Flask)

```
python app/app.py
```

Listing 2 – Execution de l'application web

Puis ouverture du navigateur sur :

`http://localhost:5000`

3.7 7) Bonnes pratiques suivies

- Separation claire entre pretraitement, entrainement, prediction et interface.
- Sauvegarde des modeles pour reutilisation sans re-entrainement.
- Pipeline reproductible grace a `requirements.txt`.

4 Captures d'ecran et preuves de travail

Cette section permet d'inserer les captures d'ecran des etapes du projet. Placez les images dans le dossier `images/` puis conservez les noms ci-dessous, ou adaptez les noms dans le code LaTeX.

4.1 Vue globale du pipeline

4.2 Sortie de pretraitement

4.3 suppression de corrélation

4.4 Performance des modeles

4.5 Interface Flask de prediction

4.6 Conseil de capture

- Utiliser des captures nettes (minimum 1280x720).
- Montrer les commandes executees et leur sortie.
- Masquer les informations sensibles avant export.

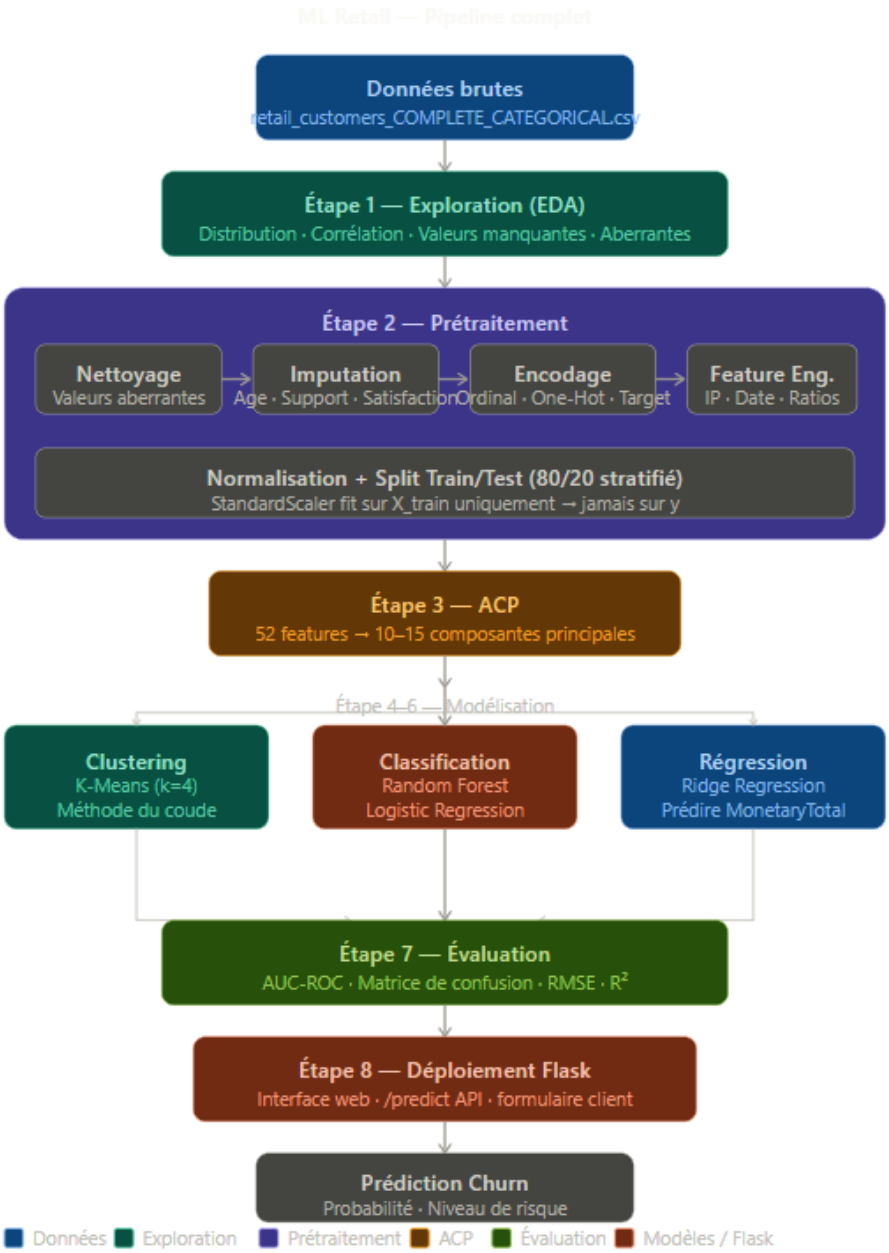

FIGURE 1 – Pipeline global du projet ML

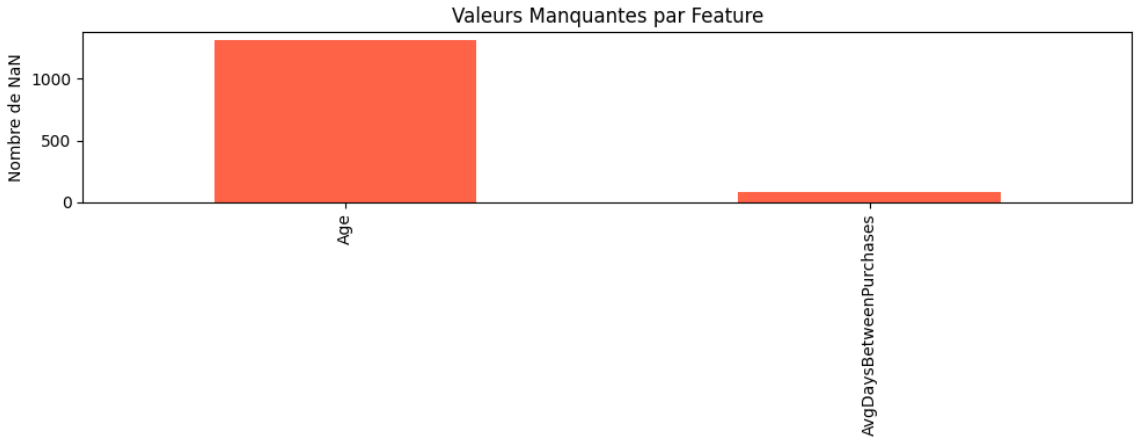

FIGURE 2 – Resultat des etapes de pretraitement

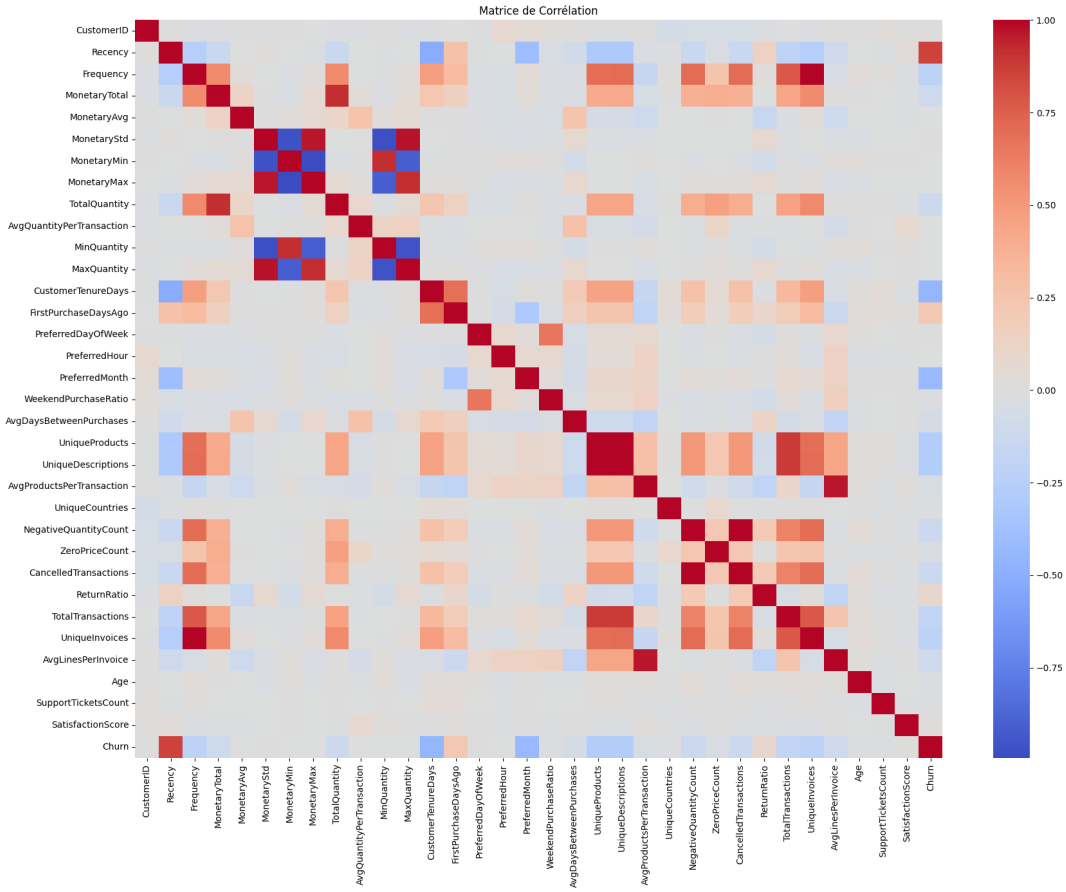

FIGURE 3 – suppression de corrélation

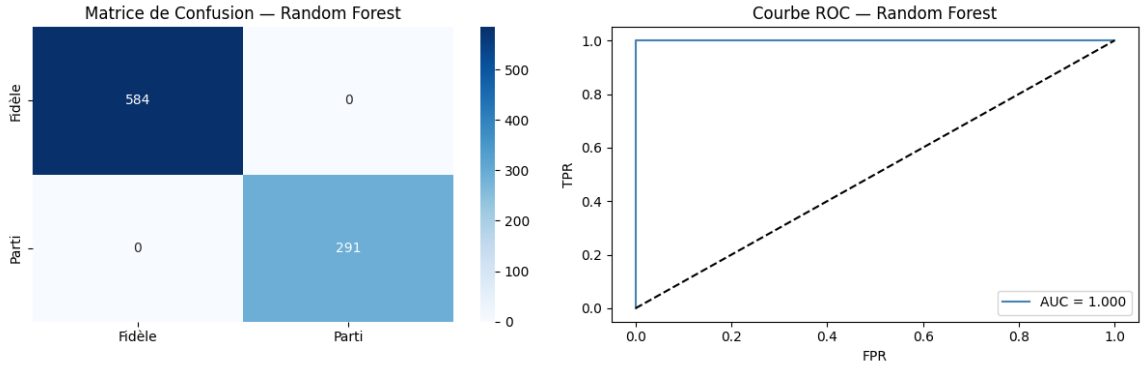

FIGURE 4 – Matrice de confusion, ROC, metriques

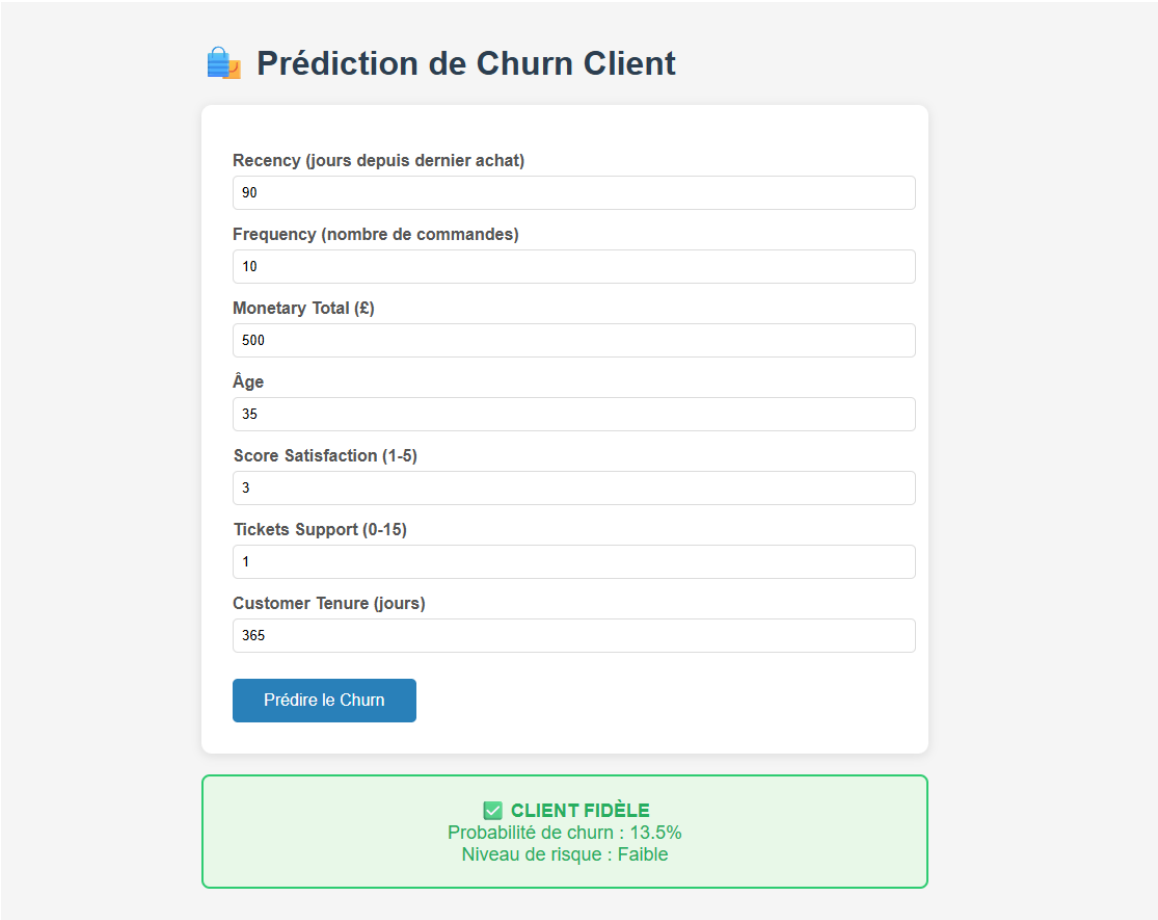

FIGURE 5 – Application web locale pour predire le churn

5 Conclusion et perspectives

Le projet a permis de construire un pipeline ML complet, de la preparation des donnees jusqu'a la prediction de churn via une interface web.

Synthese

- Pipeline reproductible et modulaire.
- Modeles sauvegardes et reutilisables.
- Visualisations et indicateurs pour soutenir l'analyse metier.

5.1 Ameliorations possibles

- Ajouter une validation croisee plus poussee pour tous les modeles.
- Tester des modeles avances (XGBoost, LightGBM).
- Deployer l'application sur un service cloud.